

Classificação de Câncer de Mama com Machine Learning

Introdução

O câncer de mama é uma das doenças com maior incidência entre as mulheres em todo o mundo. A identificação precoce da doença aumenta significativamente as chances de sucesso do tratamento, tornando o diagnóstico rápido e preciso um fator essencial.

Neste contexto, técnicas de machine learning podem ser utilizadas como ferramentas de apoio ao diagnóstico, auxiliando profissionais da saúde na classificação de tumores como benignos ou malignos a partir de características extraídas de exames clínicos.

O objetivo deste projeto é desenvolver e comparar modelos de classificação supervisionada utilizando o conjunto de dados *Breast Cancer Wisconsin Diagnostic Dataset*, avaliando seu desempenho por meio de métricas de classificação e interpretando as decisões do modelo utilizando técnicas de Inteligência Artificial Explicável (XAI).

Objetivos

Objetivo Geral

Desenvolver um sistema de classificação capaz de auxiliar na identificação de tumores benignos e malignos utilizando técnicas de Machine Learning.

Objetivos Específicos

- Realizar a análise exploratória do conjunto de dados
- Executar o pré-processamento dos dados
- Treinar diferentes modelos de classificação
- Comparar o desempenho dos modelos utilizando métricas de avaliação
- Interpretar as decisões do modelo utilizando técnicas de Explainable AI (Feature Importance e SHAP)

Dataset

Foi utilizado o *Breast Cancer Wisconsin Diagnostic Dataset*, disponibilizado pela UCI Machine Learning Repository e obtido por meio da biblioteca KaggleHub.

Optou-se pelo download automático do dataset em vez de armazenar o arquivo diretamente no repositório, garantindo maior reprodutibilidade do projeto e reduzindo o tamanho do repositório.

O conjunto de dados possui:

- 569 amostras
- 33 colunas (incluindo identificador e coluna sem utilização)
- variável alvo denominada *diagnosis*, composta por: M (Maligno) e B (Benigno)

Tecnologias utilizadas

O projeto foi desenvolvido em Python utilizando as seguintes bibliotecas:

- pandas
- numpy
- matplotlib
- seaborn
- scikit-learn
- shap
- kagglehub

Metodologia

O desenvolvimento foi dividido nas seguintes etapas:

Importação das Bibliotecas

Inicialmente foram importadas todas as bibliotecas necessárias para manipulação dos dados, visualização gráfica, treinamento dos modelos e interpretação dos resultados.

Download e Leitura do Dataset

O dataset foi obtido automaticamente utilizando a biblioteca *KaggleHub*.

Após o download, o arquivo CSV foi carregado em um DataFrame do pandas para permitir sua manipulação.

Inspeção Inicial

Foi realizada uma inspeção inicial utilizando:

- visualização das primeiras linhas
- tipos de dados
- quantidade de registros
- quantidade de atributos

Também foi identificada uma coluna denominada *Unnamed: 32*, sem informações relevantes para o problema.

Análise Exploratória dos Dados (EDA)

Nesta etapa foram realizadas:

- verificação de valores ausentes
- estatísticas descritivas
- distribuição das classes
- conversão da variável alvo
- análise das principais variáveis
- análise de correlação

A análise mostrou que o dataset não possui valores ausentes e apresenta leve desbalanceamento entre tumores benignos e malignos.

Pré-processamento

As seguintes etapas foram realizadas:

- remoção das colunas *id* e *Unnamed: 32*
- separação entre atributos (X) e variável alvo (y)
- divisão em conjuntos de treinamento (80%) e teste (20%)

- padronização dos atributos utilizando StandardScaler para os modelos sensíveis à escala

Modelos desenvolvidos

Foram avaliados três algoritmos supervisionados.

Regressão Logística

Utilizada como modelo base para classificação binária.

Características:

- simples interpretação
- boa capacidade de generalização
- exige padronização dos dados

K-Nearest Neighbors (KNN)

Modelo baseado na distância entre as amostras.

Características:

- classificação baseada nos vizinhos mais próximos
- sensível à escala dos atributos
- utiliza padronização dos dados

Random Forest

Modelo baseado em múltiplas árvores de decisão.

Características:

- elevada capacidade de classificação
- reduz overfitting
- fornece importância das variáveis
- não necessita de padronização dos atributos

Avaliação dos modelos

Os modelos foram avaliados utilizando:

- Accuracy
- Recall
- F1-Score
- Classification Report
- Matriz de Confusão

Embora todas as métricas sejam importantes, o Recall foi considerado a principal métrica deste projeto.

Isso ocorre porque, em aplicações médicas, é fundamental minimizar os falsos negativos, ou seja, evitar que tumores malignos sejam classificados como benignos.

Comparação dos modelos

Após o treinamento, foi realizada uma comparação entre os modelos utilizando as métricas de desempenho.

A comparação permitiu identificar o algoritmo com melhor capacidade de classificação para o problema proposto.

O modelo Random Forest apresentou o melhor desempenho geral, sendo escolhido para as análises de interpretabilidade.

Explicabilidade do modelo

Além da avaliação quantitativa, foram utilizadas técnicas de Inteligência Artificial Explicável (XAI).

Feature Importance

O Random Forest calcula automaticamente a importância de cada variável durante o treinamento.

Essa técnica permitiu identificar quais atributos tiveram maior influência na classificação dos tumores.

SHAP

Foi utilizada a biblioteca SHAP (SHapley Additive exPlanations).

Foram gerados: Summary Plot e Dependence Plot

Essas visualizações permitem compreender como cada variável contribuiu para as previsões do modelo, aumentando a transparência do sistema.

Resultados

Os experimentos demonstraram que os três modelos apresentaram elevado desempenho na classificação do câncer de mama.

Entre eles, o Random Forest apresentou os melhores resultados, destacando-se principalmente pela elevada capacidade de identificação dos casos malignos.

As análises de interpretabilidade mostraram que características relacionadas ao tamanho, formato e concavidade dos tumores possuem maior influência na decisão do modelo.

Conclusões

O projeto atingiu os objetivos propostos, desenvolvendo um sistema de classificação supervisionada para apoio ao diagnóstico do câncer de mama.

Foram implementadas todas as etapas do processo de Ciência de Dados, incluindo análise exploratória, pré-processamento, treinamento, avaliação dos modelos e interpretabilidade.

Os resultados demonstraram que algoritmos de Machine Learning possuem elevado potencial para auxiliar profissionais da saúde, principalmente quando associados a técnicas de Inteligência Artificial Explicável.

Entretanto, a solução desenvolvida deve ser utilizada exclusivamente como ferramenta de apoio à decisão clínica, não substituindo a avaliação realizada por profissionais médicos.